


AFH

Práctica de Cuantización



Mario Coca Atienza



Índice

Práctica	2
Punto 1	2
Punto 2	2
Punto 3	2
Punto 4	3

Práctica

Punto 1

La primera imagen muestra la lista de modelos disponibles en LM Studio. Se observan dos versiones del Phi 3 Mini (3B): una en formato F16, sin cuantización, con un tamaño de 7.12 GB, y otra cuantizada en Q4, mucho más ligera, con apenas 2.23 GB. Ambas usan el formato GGUF, pero difieren en precisión y consumo de recursos. Esta comparación inicial permite establecer la base para analizar el impacto de la cuantización sobre el rendimiento del modelo.

Your Models				Recency ↓	Size	Downloaded
Phi 3 Mini	F16	lmstudio-community	3B	ph13	GGUF	7.12 GB >
Phi 3 Mini	Q4	lmstudio-community	3B	ph13	GGUF	2.23 GB >

Punto 2

Aquí se presenta la información correspondiente al modelo no cuantizado (F16) durante su ejecución. El consumo de memoria asciende a 8.74 GB, más del doble respecto a la versión cuantizada, manteniendo el mismo contexto de procesamiento. Este hecho confirma la contrapartida esperada: mayor precisión numérica y estabilidad a costa de requerir más potencia y recursos de hardware.

Currently Loaded (1)

Memory Consumption: 8.74 GB / 16 GB

no cuantizado

Context: 4096

GGUF

Eject

Punto 3

Aquí puede verse el modelo cuantizado en ejecución. LM Studio lo identifica con el nombre “cuantización” y un contexto de 4096 tokens. El consumo de memoria se mantiene en torno a 3.85 GB de 16 GB disponibles, lo que demuestra una excelente eficiencia. Este comportamiento evidencia por qué los modelos cuantizados resultan tan útiles en entornos locales: ofrecen velocidad y ahorro de RAM sin comprometer demasiado la coherencia de sus respuestas



Punto 4

El siguiente fragmento muestra una breve prueba práctica: ambos modelos responden al mismo prompt básico, “hola”. El modelo cuantizado genera su mensaje con mayor agilidad (más de 41 tokens por segundo) mientras que el no cuantizado trabaja a una velocidad menor (unos 14 tokens por segundo). Aunque las respuestas son similares en tono y estructura, la diferencia en rendimiento evidencia el beneficio directo de la cuantización en términos de velocidad de inferencia.

