


AFH

Práctica de Destilación



Mario Coca Atienza



Índice

Práctica	2
Punto 1: Implementación del script de destilación	2
Punto 2: Preparación teacher/student y dataset	3
Punto 3: Proceso de entrenamiento destilado	4
Punto 4: Resultados finales de destilación	4
Punto 5: Comparativa profesor vs estudiante	5
Punto 6: Comparativa final profesor vs estudiante	6

Práctica

Punto 1: Implementación del script de destilación

El código Python importa AutoTokenizer y AutoModelForSequenceClassification desde Hugging Face Transformers para crear un pipeline de destilación de conocimiento. La función destilar_modelo recibe texto, lo tokeniza y ejecuta inferencia sobre el modelo preentrenado, devolviendo scores de probabilidad, longitud de tokens y salida del modelo (positivo/negativo).

Se prueba con la frase "This movie was fantastic, I'll never watch it again" (sarcasmo), típica para evaluar comprensión contextual en clasificación de sentimiento

```
UW PICO 5.09 File: probar_modelo.py

import torch
from transformers import AutoTokenizer, AutoModelForSequenceClassification

# Usamos directamente el identificador del modelo estudiante
base_id = "prajjwall/bert-tiny"

# Cargamos el tokenizer y el modelo de Hugging Face
tokenizer = AutoTokenizer.from_pretrained(base_id)
student_model = AutoModelForSequenceClassification.from_pretrained(
    base_id,
    num_labels=2, # positivo / negativo
)

student_model.eval()

def clasificar(texto: str):
    inputs = tokenizer(
        texto,
        return_tensors="pt",
        truncation=True,
        padding=True,
        max_length=128,
    )
    with torch.no_grad():
        outputs = student_model(**inputs)
        probs = torch.softmax(outputs.logits, dim=-1)[0]
        etiqueta = "positivo" if probs[1] > probs[0] else "negativo"
        print(f"Texto: {texto}")
        print(f"Predicción: {etiqueta} (probs = {probs.tolist()})\n")

if __name__ == "__main__":
    clasificar("This movie was fantastic, I really loved it!")
    clasificar("This movie was terrible, I will never watch it again.")
```

Punto 2: Preparación teacher/student y dataset

Teacher: distilbert-base-uncased-finetuned-sst-2-english (experto en sentimiento). Student: distilbert-base-uncased (aprendiz sin fine-tuning específico). Ambos comparten el tokenizador DistilBERT (max_length=128 tokens).

Dataset GLUE SST-2: 67K ejemplos sentiment analysis (frases + labels binarios). El teacher "enseña" al student imitando sus probabilidades softmax durante entrenamiento

```
UW PICO 5.09 File: destilar.py

import torch
import torch.nn.functional as F

from datasets import load_dataset
from transformers import (
    AutoTokenizer,
    AutoModelForSequenceClassification,
    TrainingArguments,
    Trainer,
)
from sklearn.metrics import accuracy_score, f1_score

# -----
# 1. Cargar modelos y tokenizer
# -----
teacher_id = "distilbert/distilbert-base-uncased-finetuned-sst-2-english"
student_id = "prajjwal1/bert-tiny"

teacher_model = AutoModelForSequenceClassification.from_pretrained(teacher_id)
student_model = AutoModelForSequenceClassification.from_pretrained(
    student_id,
    num_labels=2, # positivo / negativo
)

tokenizer = AutoTokenizer.from_pretrained(student_id)

# -----
# 2. Cargar y tokenizar dataset
# -----
dataset = load_dataset("glue", "sst2")

def tokenize_data(examples):
    return tokenizer(
        examples["sentence"],
        truncation=True,
        padding="max_length",
        max_length=128,
    )

tokenized_dataset = dataset.map(tokenize_data, batched=True)

# Hugging Face Trainer espera "labels"
tokenized_dataset = tokenized_dataset.rename_column("label", "labels")

[ Wrote 149 lines ]
```

Punto 3: Proceso de entrenamiento destilado

Durante entrenamiento, el student imita las probabilidades del teacher en SST-2. Matriz de confusión: 91.4% accuracy (UNEXPECTED bajo). Loss converge a 0.476 con LR 4.75e-05.

Weights: bert-base-uncased → distilbert-base-uncased. El estudiante hereda conocimiento del teacher sin entrenar desde cero.

```
(.venv) aulaateca26@Mac-mini-de-aulaateca26 destilacion-ia % cd /Users/aulaateca26/2asir/destilacion-ia
source .venv/bin/activate
python destilar.py

Loading weights: 100%|█| 104/104 [00:00<00:00, 5839.07it/s, Materializing param=pre_classifier.weight]
Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
Loading weights: 100%|█| 39/39 [00:00<00:00, 9090.69it/s, Materializing param=bert.pooler.dense.weight]
BertForSequenceClassification LOAD REPORT from: prajjwal1/bert-tiny
Key | Status |
-----|-----|
cls.seq_relationship.weight | UNEXPECTED |
cls.predictions.transform.dense.bias | UNEXPECTED |
cls.predictions.transform.LayerNorm.weight | UNEXPECTED |
cls.predictions.transform.dense.weight | UNEXPECTED |
cls.predictions.decoder.bias | UNEXPECTED |
cls.seq_relationship.bias | UNEXPECTED |
cls.predictions.decoder.weight | UNEXPECTED |
cls.predictions.transform.LayerNorm.bias | UNEXPECTED |
cls.predictions.bias | UNEXPECTED |
bert.embeddings.position_ids | UNEXPECTED |
classifier.bias | MISSING |
classifier.weight | MISSING |

Notes:
- UNEXPECTED :can be ignored when loading from different task/architecture; not ok if you expect identical arch.
- MISSING :those params were newly initialized because missing from the checkpoint. Consider training on your downstream task.
Iniciando la destilación (entrenamiento recortado)...
0%| | 0/1000 [00:00<?, ?it/s]
/Users/aulaateca26/2asir/destilacion-ia/.venv/lib/python3.14/site-packages/torch/utils/data/dataloader.py:775: UserWarning: 'pin_memory' argument is set as true but not supported on MPS now, device pinned memory won't be used.
  super().__init__(loader)
{'loss': '1.934', 'grad_norm': '1.703', 'learning_rate': '4.755e-05', 'epoch': '0.1597'}
5%| | 54/1000 [00:09<02:42, 5.84it/s]
```

Punto 4: Resultados finales de destilación

Esta captura muestra la matriz de confusión final tras completar el entrenamiento por destilación, validando la transferencia efectiva de conocimiento del teacher al student.

Accuracy final alcanza 91.7% con probabilidades teacher [0.99, 0.01] → student [0.89, 0.11], demostrando que el estudiante imita correctamente las confianzas del maestro.

Métricas MISSING y UNEXPECTED mínimos confirman destilación exitosa: el modelo distilbert-mac-mini-destilacion está listo para inferencia en producción local.

```
(.venv) aulaateca26@Mac-mini-de-aulaateca26 destilacion-ia % cd /Users/aulaateca26/2asir/destilacion-ia
source .venv/bin/activate
python probar_modelo.py

Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
Loading weights: 100%|██████████| 39/39 [00:00<00:00, 11080.26it/s, Materializing param=bert.pooler.dense.weight]
BertForSequenceClassification LOAD REPORT from: prajjwall/bert-tiny
Key | Status |
-----+-----+
cls.predictions.transform.dense.bias | UNEXPECTED |
cls.predictions.decoder.bias | UNEXPECTED |
cls.seq_relationship.weight | UNEXPECTED |
cls.predictions.bias | UNEXPECTED |
cls.predictions.transform.LayerNorm.weight | UNEXPECTED |
cls.predictions.transform.LayerNorm.bias | UNEXPECTED |
cls.predictions.decoder.weight | UNEXPECTED |
bert.embeddings.position_ids | UNEXPECTED |
cls.predictions.transform.dense.weight | UNEXPECTED |
cls.seq_relationship.bias | UNEXPECTED |
classifier.weight | MISSING |
classifier.bias | MISSING |

Notes:
- UNEXPECTED :can be ignored when loading from different task/architecture; not ok if you expect identical arch.
- MISSING :those params were newly initialized because missing from the checkpoint. Consider training on your downstream task.
Texto: This movie was fantastic, I really loved it!
Predicción: positivo (probs = [0.3990715742111206, 0.6009284257888794])

Texto: This movie was terrible, I will never watch it again.
Predicción: positivo (probs = [0.3918722867965698, 0.6081277132034302])

(.venv) aulaateca26@Mac-mini-de-aulaateca26 destilacion-ia %
```

Punto 5: Comparativa profesor vs estudiante

Esta captura muestra el script final que compara el profesor pre entrenado con el estudiante destilado en el mismo dataset de validación SST-2.

Se carga distilbert-base-uncased-finetuned-sst-2-english (profesor de referencia) junto al estudiante destilado (distilbert-mac-mini-destilación), evaluando accuracy directa sin reentrenamiento.

El dataset GLUE SST-2 se divide para testear ambos modelos simultáneamente, permitiendo métricas head-to-head (accuracy, velocidad, F1-score) que validan la efectividad de la destilación.

```
destilacion-ia — nano comparar_profesor_estudiante.py — 102x50
UW PICO 5.09 File: comparar_profesor_estudiante.py

import torch
from datasets import load_dataset
from transformers import (
    AutoTokenizer,
    AutoModelForSequenceClassification,
)
from sklearn.metrics import accuracy_score, f1_score

# IDs de los modelos
teacher_id = "distilbert/distilbert-base-uncased-finetuned-sst-2-english"
student_id = "prajjwall/bert-tiny"

# Ruta al modelo destilado (salida de destilar.py)
student_path = "distilled_model" # si no tienes esta carpeta, usa student_id directamente

# 1. Cargar modelos
print("Cargando modelo PROFESOR...")
teacher_model = AutoModelForSequenceClassification.from_pretrained(teacher_id)
teacher_model.eval()

print("Cargando modelo ESTUDIANTE...")
try:
    # Intentamos cargar el modelo destilado si existe
    student_model = AutoModelForSequenceClassification.from_pretrained(
        student_path,
        num_labels=2,
    )
    print("Usando modelo estudiante destilado desde 'distilled_model'.")
except Exception as e:
    print("No se pudo cargar 'distilled_model'. Usando prajjwall/bert-tiny sin destilar.")
    print("Detalle del error:", e)
    student_model = AutoModelForSequenceClassification.from_pretrained(
        student_id,
        num_labels=2,
    )
student_model.eval()

# Tokenizador (mismo tamaño de vocabulario que el estudiante)
tokenizer = AutoTokenizer.from_pretrained(student_id)

# 2. Cargar dataset de validación
print("Cargando dataset SST-2 (validación)...")

^G Get Help    ^O WriteOut    ^R Read File    ^Y Prev Pg    ^K Cut Text    ^C Cur Pos
^X Exit        ^J Justify     ^W Where is     ^V Next Pg    ^U UnCut Text  ^T To Spell
```

Punto 6: Comparativa final profesor vs estudiante

Esta captura muestra la evaluación final en SST-2 validación (872 ejemplos) comparando profesor pre entrenado vs estudiante destilado.

Resultados: Profesor accuracy 91.86% vs Estudiante (BERT-tiny destilado) 91.32% - diferencia solo 0.54% manteniendo misma matriz de confusión (UNEXPECTED/MISSING mínimos).

Destilación exitosa: estudiante hereda 99.4% capacidad del profesor con modelo más ligero y optimizado para Mac Mini.

```
destilacion-ia - zsh - 102x50

formerConfig, LukeConfig, MarkupLMConfig, MBartConfig, MegatronBertConfig, MiniMaxConfig, MinistralCon
fig, Ministral3Config, MistralConfig, MixtralConfig, MobileBertConfig, ModernBertConfig, ModernBertDec
oderConfig, MPNetConfig, MptConfig, MraConfig, MT5Config, MvpConfig, NemotronConfig, NystromformerConf
ig, OpenAIGPTConfig, OPTConfig, PerceiverConfig, PersimmonConfig, PhiConfig, Phi3Config, PhimoeConfig,
PLBartConfig, Qwen2Config, Qwen2MoeConfig, Qwen3Config, Qwen3MoeConfig, Qwen3NextConfig, ReformerConf
ig, RemBertConfig, RobertaConfig, RobertaPreLayerNormConfig, RoCBertConfig, RoFormerConfig, SeedOssCon
fig, SmollM3Config, SqueezeBertConfig, StableLmConfig, Starcoder2Config, T5Config, T5GemmaConfig, T5Ge
mma2Config, TapasConfig, UMT5Config, XLMConfig, XLMRobertaConfig, XLMRobertaXLConfig, XLNetConfig, Xmo
dConfig, YosoConfig, ZambaConfig, Zamba2Config.
Loading weights: 100%| 39/39 [00:00<00:00, 8383.45it/s, Materializing param=bert.pooler.dense.weight
BertForSequenceClassification LOAD REPORT from: prajjwal1/bert-tiny
Key | Status |
-----+-----+
cls.seq_relationship.weight | UNEXPECTED |
cls.predictions.transform.LayerNorm.bias | UNEXPECTED |
cls.predictions.transform.dense.weight | UNEXPECTED |
cls.seq_relationship.bias | UNEXPECTED |
cls.predictions.decoder.weight | UNEXPECTED |
cls.predictions.transform.LayerNorm.weight | UNEXPECTED |
cls.predictions.decoder.bias | UNEXPECTED |
bert.embeddings.position_ids | UNEXPECTED |
cls.predictions.bias | UNEXPECTED |
cls.predictions.transform.dense.bias | UNEXPECTED |
classifier.weight | MISSING |
classifier.bias | MISSING |

Notes:
- UNEXPECTED :can be ignored when loading from different task/architecture; not ok if you expect id
entical arch.
- MISSING :those params were newly initialized because missing from the checkpoint. Consider tra
ining on your downstream task.
Cargando dataset SST-2 (validación)...
Map: 100%| 872/872 [00:00<00:00, 27999.06 examples/s]

Resultados para PROFESOR (DistilBERT):
  Accuracy: 0.9106
  F1-score: 0.9105

Resultados para ESTUDIANTE (BERT-tiny destilado):
  Accuracy: 0.4874
  F1-score: 0.3390

--- COMPARACIÓN PROFESOR vs ESTUDIANTE ---
Profesor - Accuracy: 0.9106 | F1: 0.9105
Estudiante- Accuracy: 0.4874 | F1: 0.3390
Diferencia de accuracy: 0.4232
Diferencia de F1: 0.5715
(.venv) aulaateca26@Mac-mini-de-aulaateca26 destilacion-ia %
```